

UnICEUB

Ciência de Dados e Machine Learning

Data Mart e Data Mesh

Conceitos, implementação com dados sintéticos, dashboards e análise aplicados a uma rede de farmácias no Distrito Federal

Rafael Robson Nunes de Araújo

rafael.robson@sempreceub.com

Turma A - 0726 - Campus Virtual - 2026/2

Brasília, setembro de 2026

Sumário

Introdução.....	3
Parte 1. Conceitos.....	4
1.1 Definição de Data Mart.....	4
1.2 Definição de Data Mesh.....	4
1.3 Diferença de abordagem e objetivo de cada um.....	5
1.4 Esquemas de implementação.....	6
Parte 2. Dados sintéticos e implementação.....	8
2.1 Dados sintéticos para o Data Mart.....	8
2.2 Dados sintéticos para o Data Mesh.....	9
2.3 Implementação.....	9
Parte 3. Dashboards.....	12
3.1 Dashboard do Data Mart: painel comercial.....	12
3.2 Dashboard do Data Mesh: painel integrado entre domínios.....	13
Parte 4. Análise dos dashboards.....	15
4.1 Análise do dashboard do Data Mart.....	15
4.2 Análise do dashboard do Data Mesh.....	16
Conclusão.....	20
Referências.....	21
Apêndice. Como reproduzir.....	22

Introdução

Este relatório compara duas formas de organizar dados analíticos: o **Data Mart**, que concentra dados de uma área de negócio em um modelo dimensional mantido por um time central, e o **Data Mesh**, que distribui a responsabilidade pelos dados entre os domínios que os produzem. A comparação não fica só no conceito. As duas abordagens foram implementadas sobre o mesmo cenário, com dados sintéticos, e cada uma alimenta um dashboard analisado ao final.

O cenário é a **Ipê Farma**, uma rede fictícia com 18 farmácias em regiões administrativas do DF, um centro de distribuição no SIA que atende o site e o app, cerca de 28 mil clientes cadastrados e 420 produtos em 10 categorias. A escolha de uma única empresa para os dois casos é proposital: fica mais fácil ver o que cada arquitetura permite responder.

Estrutura do documento

- **Parte 1:** definições, diferenças de abordagem e esquemas de implementação.
- **Parte 2:** geração dos dados sintéticos e implementação do Data Mart e do Data Mesh.
- **Parte 3:** dashboards de cada caso.
- **Parte 4:** análise dos dashboards.

Artefatos entregues junto com este relatório

Tabela 1. Arquivos entregues

Arquivo	Conteúdo
dashboard_datamart.html	Painel comercial do Data Mart, interativo, abre offline em qualquer navegador
dashboard_datamesh.html	Painel integrado entre domínios do Data Mesh, interativo e offline
codigo_datamart_datamesh.zip	Geradores de dados, ETL e SQL do mart, plataforma, contratos e pipelines do mesh, scripts dos dashboards

Todos os geradores usam semente fixa. Rodar os scripts na ordem descrita no Apêndice reproduz exatamente os números citados aqui.

Parte 1. Conceitos

1.1 Definição de Data Mart

Data Mart é um repositório analítico voltado a uma área de negócio ou a um assunto específico, como vendas, finanças ou recursos humanos. Ele reúne apenas os dados que aquele público precisa, já integrados, limpos e organizados para consulta, normalmente em **modelagem dimensional**: tabelas fato com as medidas do processo de negócio e tabelas de dimensão com o contexto para filtrar e agrupar essas medidas (Kimball e Ross, 2013).

Na visão de Inmon (2005), o data mart é um subconjunto departamental derivado de um data warehouse corporativo. Na visão de Kimball, o próprio data warehouse é formado pela união de data marts que compartilham **dimensões conformadas**. As duas visões convivem na prática e definem três tipos comuns:

- **Dependente:** alimentado a partir do data warehouse corporativo, herda suas regras de integração.
- **Independente:** alimentado direto das fontes operacionais, sem passar por um warehouse. É mais rápido de construir, mas tende a criar silos.
- **Híbrido:** combina dados do warehouse com fontes específicas da área.

Suas características centrais são escopo delimitado, volume menor que o de um warehouse, esquema otimizado para leitura (estrela ou floco de neve), carga em lote por processos de ETL ou ELT e um time de dados central responsável por pipeline, modelo e qualidade.

1.2 Definição de Data Mesh

Data Mesh é uma abordagem sociotécnica e descentralizada para dados analíticos, proposta por Zhamak Dehghani em 2019 e consolidada em livro em 2022. Em vez de mover todos os dados para uma plataforma central operada por um único time, a responsabilidade pelos dados analíticos fica com os **domínios de negócio** que os geram e melhor os entendem. Esses domínios publicam seus dados como **produtos**, sobre uma plataforma comum, seguindo regras de governança definidas em conjunto.

A proposta se apoia em quatro princípios que funcionam juntos:

1. **Propriedade orientada a domínio.** Cada domínio (vendas, logística, clientes, marketing) é dono dos dados analíticos que produz, do pipeline à publicação.
2. **Dados como produto.** O que um domínio publica tem dono, contrato, documentação, SLA e métricas de qualidade. Um bom produto de dados é descobrível, endereçável, confiável, autodescritivo, interoperável e seguro.
3. **Plataforma de dados self-serve.** Um time de plataforma oferece a infraestrutura comum (armazenamento, validação, catálogo, controle de acesso) para que os domínios publiquem sem reinventar essas peças.
4. **Governança computacional federada.** Um grupo com representantes dos domínios define padrões globais (identificadores, privacidade, formatos), e a plataforma os aplica automaticamente, em código, no momento da publicação.

Data Mesh não é uma tecnologia nem um produto que se compra. É uma forma de distribuir responsabilidade e arquitetura, que pode usar data lakes, warehouses ou lakehouses por baixo.

1.3 Diferença de abordagem e objetivo de cada um

A diferença essencial está em **quem é dono dos dados e onde fica a integração**. No Data Mart, um time central extrai dados das fontes, integra e entrega um modelo pronto para uma área. No Data Mesh, cada domínio integra e publica o próprio dado, e o cruzamento entre domínios acontece no consumo, apoiado em identificadores e padrões comuns.

Tabela 2. Comparação entre as abordagens

Dimensão	Data Mart	Data Mesh
Unidade de organização	Área de negócio ou assunto consumidor	Domínio produtor dos dados
Propriedade	Time central de dados ou BI	Times de domínio, com apoio de um time de plataforma
Arquitetura	Centralizada; um banco analítico por área	Distribuída; vários produtos de dados interoperáveis
Fluxo	Fontes → ETL central → mart → consumidores	Fontes do domínio → pipeline do domínio → produto → qualquer consumidor autorizado
Modelagem	Dimensional, desenhada para as perguntas da área	Cada produto define seu grão e esquema em contrato; padrões globais garantem junção
Qualidade	Garantida pelo time central no ETL	Garantida pelo dono do produto e verificada pela plataforma
Governança	Centralizada, por processo e revisão	Federada e automatizada em código
Ponto forte	Simplicidade, consistência, entrega rápida para uma área	Escala organizacional, autonomia, dados cruzados entre áreas
Risco típico	Gargalo no time central; silos quando há muitos marts independentes	Custo de coordenação; exige maturidade técnica nos domínios
Quando faz sentido	Poucos domínios, uma área com necessidade clara, time de dados pequeno	Muitos domínios, fontes heterogêneas, alta demanda por dados entre áreas

Objetivo principal de cada um

O objetivo principal do **Data Mart** é **entregar a uma área de negócio um conjunto de dados confiável, integrado e fácil de consultar**, que responda às perguntas recorrentes daquela área com bom desempenho e com uma única versão dos números.

O objetivo principal do **Data Mesh** é **escalar o uso de dados analíticos em organizações com muitos domínios**, eliminando o gargalo do time central. Ele faz isso ao colocar a responsabilidade nos domínios que conhecem os dados e ao garantir, por produto e por plataforma, que esses dados possam ser encontrados, confiados e combinados.

As abordagens não são excludentes. Em um Data Mesh maduro, o domínio de vendas pode publicar como produto exatamente um data mart dimensional. O que muda é quem é dono dele, como ele é descoberto e sob quais regras outros domínios podem usá-lo.

1.4 Esquemas de implementação

Data Mart

A Figura 1 mostra a implementação usada neste trabalho. Quatro sistemas operacionais exportam arquivos, a camada de staging padroniza tipos e remove o que não deve seguir adiante, e o ETL só publica o mart se todos os portões de qualidade passarem. O consumo lê o banco final.



Figura 1. Arquitetura de implementação do Data Mart comercial

A Figura 2 detalha o modelo dimensional. A `fato_vendas` tem grão de item de pedido, o menor nível disponível no PDV, o que permite agregar para qualquer combinação de dimensões. A `fato_meta_mensal` tem grão diferente (loja por mês) e por isso fica em tabela própria, compartilhando a `dim_loja`. A `dim_cliente` guarda só atributos para segmentação.




Figura 2. Esquema estrela do Data Mart comercial

Data Mesh

A Figura 3 mostra os quatro domínios, cada um com fontes em formatos próprios e seu pipeline. Acima deles fica a governança federada, que define as políticas. Abaixo fica a plataforma, que valida contratos, aplica essas políticas e registra tudo no catálogo. O consumo entre domínios só lê produtos publicados, pelo catálogo.

Data Mesh da Ipê Farma: arquitetura de implementação

Quatro domínios donos dos próprios dados publicam produtos com contrato. A plataforma oferece a infraestrutura comum e aplica as políticas definidas pela governança federada.




Figura 3. Arquitetura de implementação do Data Mesh

O elemento central do mesh é o **contrato do produto de dados**. Abaixo está um trecho do contrato de `vendas.pedidos`, que declara dono, classificação de acesso, SLA, esquema e regras de qualidade escritas em SQL.

Trecho de `datamesh/dominios/vendas/contratos/pedidos.yaml`

```
id: vendas.pedidos
dominio: vendas
versao: "1.2.0"
dono: squad-vendas@ipefarma.com.br
classificacao: interno
granularidade: pedido
sla: {atualizacao: diaria 04h, frescor_max_horas: 36, coluna_tempo: data_hora}
esquema:
  - {nome: pedido_id, tipo: string, obrigatorio: true, unico: true}
  - {nome: canal, tipo: string, valores: [Loja física, Site, App]}
  - {nome: cliente_pid, tipo: string, pseudonimo: true}
  - {nome: valor_liquido_brl, tipo: decimal, obrigatorio: true, min: 0}
qualidade:
  - {nome: liquido igual bruto menos desconto,
    condicao: "abs(valor_liquido_brl - (valor_bruto_brl - desconto_brl)) < 0.01"}
  - {nome: campanha so em canal digital,
    condicao: "campanha_id IS NULL OR canal <> 'Loja física'"}

```

Parte 2. Dados sintéticos e implementação

2.1 Dados sintéticos para o Data Mart

O script `datamart/gerar_fontes.py` simula as exportações dos sistemas da Ipê Farma entre janeiro de 2024 e junho de 2026. Os cadastros de lojas, produtos e clientes vêm de um módulo compartilhado (`comum/mundo.py`), com CPFs sintéticos que respeitam os dígitos verificadores e são garantidamente únicos.

Tabela 3. Fontes geradas para o Data Mart

Arquivo	Sistema de origem	Conteúdo	Linhas
<code>pdv_pedidos.csv</code>	PDV	Cabeçalho do pedido: data e hora, loja, canal, cliente, pagamento, status	571.585
<code>pdv_itens_pedido.csv</code>	PDV	Itens: SKU, quantidade, preço, desconto, custo	1.189.625
<code>erp_produtos.csv</code>	ERP	SKU, categoria, marca, preço e custo base, controlado	420
<code>erp_lojas.csv</code>	ERP	Lojas, região, RA, inauguração	19
<code>crm_clientes.csv</code>	CRM	Nome, CPF, e-mail, telefone, sexo, nascimento, RA, tier, consentimento	28.000
<code>plan_metas_mensais.csv</code>	Planejamento	Meta de receita por loja e mês	556

Para que os dados tivessem padrões reais a descobrir no dashboard, a simulação combina vários efeitos multiplicativos sobre a demanda diária de cada loja:

- **Porte da loja**, de 0,60 (Park Way) a 1,45 (Asa Sul), e **dia da semana**, com sábado 18% acima da média e domingo 23% abaixo.
- **Sazonalidade mensal**, com pico em dezembro e alta no inverno seco de Brasília (maio a agosto), quando antigripais pesam 65% mais no mix.
- **Black Friday**, com 30% mais pedidos na semana e descontos de 15% a 25%, e **Natal**, com 18% mais na quinzena anterior.
- **Tendências por loja**: Planaltina perde 9% ao ano, Águas Claras Araucárias cresce 8%. A loja Águas Claras Rua 12 abre em março de 2025 com rampa de seis meses.
- **Canais digitais**: o app parte de 35% dos pedidos digitais e cresce 16 p.p. ao ano. O ticket digital é maior porque a cesta tem mais itens.
- **Pagamento**: Pix ganha 10 p.p. ao ano e o débito perde espaço. **Inflação** de 4,5% ao ano sobre preço e custo.
- **Metas** calculadas a partir da demanda esperada, com ambição maior para algumas lojas (25% acima para a loja nova e 12% para Planaltina).

Também foram inseridos problemas típicos de exportação, para que o ETL tivesse trabalho real: 1.710 pedidos duplicados, 1,9% de pedidos cancelados, devoluções com quantidade negativa, vendas sem cliente identificado, datas em `dd/mm/aaaa`, decimais com vírgula e separador ponto e vírgula.

2.2 Dados sintéticos para o Data Mesh

O script `datamesh/gerar_fontes.py` cobre janeiro de 2025 a junho de 2026. A diferença em relação ao mart é que **cada domínio recebe as próprias fontes, em formatos diferentes**, como aconteceria com sistemas de fornecedores distintos. Isso obriga cada domínio a tratar sua heterogeneidade antes de publicar.

Tabela 4. Fontes geradas para o Data Mesh

Domínio	Fonte e formato	Volume
Vendas	Eventos do PDV em JSON Lines, um arquivo por mês, com CPF em claro e UTM da campanha	178.495 eventos
Logística	WMS em CSV com COD_FILIAL, datas AAAAMMDD e decimal com vírgula; API do TMS em JSON aninhado	586.020 posições; 49.631 envios
Clientes	Export da ferramenta de pesquisa com colunas em inglês, e-mail e CPF; cadastro do CRM	10.147 respostas; 28.000 cadastros
Marketing	Cinco CSVs, um por rede (Google, Meta, TikTok, e-mail, push), e planilha de campanhas	1.802 linhas; 20 campanhas

Os dados foram simulados com **relações causais entre domínios**, justamente o tipo de relação que só aparece quando os produtos são cruzados:

- **Ruptura de estoque** com taxa base por loja (Planaltina 8,5%, Gama 6,8%, Sobradinho 4,8%, demais entre 1,2% e 3,6%), uma crise de antigripais entre junho e julho de 2025 e uma greve de fornecedor que afeta a região Norte em março de 2026. A ruptura reduz as vendas do dia.
- **Atraso de entrega** com probabilidade maior no período de chuvas (novembro a março), para RAs distantes do CD e durante a migração do sistema de transporte, entre outubro e novembro de 2025.
- **Nota NPS** que parte de uma base por loja e cai com atraso (até 3,4 pontos acima de 2 horas), extravio e ruptura no dia da compra.
- **Campanhas** com ROAS de referência diferente por rede e pedidos atribuídos por UTM. Os pedidos de e-mail e push vêm de clientes sorteados sem olhar o consentimento, o que simula uma falha de segmentação.

2.3 Implementação

Data Mart

O mart foi implementado em **DuckDB**, banco analítico colunar embarcado, orquestrado por `datamart/etl.py`. A carga recria o banco do zero a cada execução e segue quatro etapas:

1. `01_schema.sql` cria os schemas `stg`, `mart` e `audit` e as tabelas do modelo estrela, com chaves primárias e estrangeiras.
2. `02_staging.sql` lê os CSVs como texto, converte tipos, padroniza datas e decimais, remove duplicatas e descarta colunas pessoais do CRM.
3. O orquestrador roda as checagens de staging. Qualquer falha grava o resultado em `audit.carga` e aborta a carga.

4. `03_carga.sql` popula dimensões com chaves substitutas, carrega as fatos e cria as views. Em seguida rodam as checagens do mart e o schema de staging é removido.

Tabela 5. Resultado da carga do Data Mart

Etapa	Checagem	Resultado
staging	pedido_id único após deduplicação	OK
staging	itens órfãos (sem pedido)	OK, 0
staging	SKU inexistente no cadastro	OK, 0
staging	preço não positivo; desconto fora de 0 a 50%	OK, 0
staging	duplicatas removidas / cancelados excluídos	1.710 / 10.778
mart	fato sem data válida na dim_tempo	OK, 0
mart	margem = receita líquida menos custo	OK, 0
mart	receita da fato conciliada com staging	OK, diferença R\$ 0
mart	linhas na fato_vendas / devoluções	1.164.367 / 2.155

A carga completa leva cerca de 15 segundos. Duas decisões de projeto merecem registro. Primeiro, a `dim_cliente` tem um membro `-1` para vendas sem identificação, o que evita chaves nulas na fato. Segundo, o mart segue o princípio de minimização da LGPD: nome, CPF, e-mail e telefone não entram, porque nenhuma pergunta comercial precisa deles.

Data Mesh

O mesh foi implementado em Python, com DuckDB e pandas nos pipelines e Parquet como formato das portas de saída. O código fica em três camadas:

Estrutura do Data Mesh

```
datamesh/
  plataforma/
    contrato.py      time de plataforma
    governanca.py    leitura do YAML e validação de esquema e regras
    catalogo.py      pseudonimização HMAC, varredura de PII, políticas globais
                    publicação atômica, catálogo, leitura com autorização
  dominios/
    vendas/          fontes/ contratos/ pipeline.py produtos/
    logistica/       fontes/ contratos/ pipeline.py produtos/
    clientes/        fontes/ contratos/ pipeline.py produtos/
    marketing/       fontes/ contratos/ pipeline.py produtos/
    consumo/analises.py cruzamentos entre domínios
    rodar_mesh.py
```

Cada domínio escreve seu pipeline como preferir e chama uma única função da plataforma, `catalogo.publicar(contrato, dataframe)`. A publicação executa, nesta ordem:

- **Validação do contrato:** colunas declaradas e nenhuma coluna extra, tipos, obrigatoriedade, unicidade, domínio de valores, mínimos e máximos, volume mínimo e regras SQL do dono.
- **Políticas globais da governança:** nomes em snake_case, sufixo `_brl` em valores monetários, varredura de CPF, e-mail e telefone em claro, e coerência entre classificação e presença de

dado pessoal. Pela LGPD, dado pseudonimizado continua sendo pessoal e não pode ser público.

- **SLA de frescor:** idade do dado mais recente comparada ao limite do contrato.
- **Gravação atômica:** se tudo passar, o Parquet é escrito em arquivo temporário e renomeado para `produtos/<nome>/v<major>/dados.parquet`. Se algo falhar, nada é gravado e o consumidor continua vendo a versão anterior, quando existe.
- **Registro no catálogo:** produto, execução, cada checagem, linhagem e consumidores autorizados.

Três cuidados de segurança foram implementados na plataforma. O identificador global de cliente é um **HMAC-SHA256** do CPF com chave lida da variável de ambiente `MESH_PSEUDO_KEY`, que exige no mínimo 32 caracteres; todos os domínios geram o mesmo pseudônimo sem que o CPF circule. As regras SQL dos contratos rodam em um DuckDB isolado, com **acesso externo desativado e configuração travada**, para que um contrato não consiga ler arquivos do servidor. E toda leitura passa por `catalogo.ler(produto, consumidor)`, que bloqueia produtos restritos para quem não está autorizado e registra cada acesso, liberado ou negado.

Tabela 6. Execução do Data Mesh

Produto	Classificação	Linhas	Checagens	Status
vendas.pedidos	interno	178.495	23	publicado
vendas.vendas_diarias_loja	público interno	10.858	15	publicado
logistica.ruptura_diaria_loja	público interno	9.767	19	publicado
logistica.entregas	interno	49.631	17	publicado
clientes.respostas_nps	interno	10.147	17	publicado
clientes.perfil_cliente	restrito	28.000	12	publicado
marketing.campanhas	público interno	20	13	publicado
marketing.investimento_diario	público interno	1.802	14	publicado
clientes.respostas_nps_rascunho	público interno	10.147	10 (2 falhas)	rejeitado

A última linha é uma demonstração intencional. O domínio de clientes tentou publicar uma primeira versão das respostas NPS com a coluna de e-mail e uma coluna chamada **Loja**. A plataforma bloqueou por **PII em claro** e por **nome fora do padrão**. Na camada de consumo, também foi simulado um consumidor externo (`parceiro_externo_trade`) tentando ler o perfil de clientes, e o acesso foi negado e registrado.

Por fim, `consumo/analises.py` lê os oito produtos como `diretoria_bi` e faz os cruzamentos: NPS por situação da entrega (junção por `pedido_id`), NPS por ruptura da loja no dia (por `loja_id` e data), ROAS por campanha e pedidos de e-mail e push de clientes sem consentimento (por `campanha_id` e `cliente_pid`). O resultado alimenta o dashboard da Parte 3.

Parte 3. Dashboards

Os dois dashboards foram construídos em HTML, com os dados agregados embutidos, Chart.js e fonte incorporados. Abrem offline em qualquer navegador e recalculam todos os indicadores quando o filtro muda. As figuras abaixo mostram o estado padrão de cada um.

3.1 Dashboard do Data Mart: painel comercial

O público é a diretoria comercial. Há três filtros combináveis: período (últimos 12 meses, 1º semestre de 2026, 2025 e 2024), região (Plano Piloto, Oeste, Sul, Norte ou canal digital) e canal (loja física, site ou app). Cada indicador do topo compara com o período anterior de mesma duração e traz uma minissérie mensal.




Figura 4. Indicadores do período, receita mensal por canal com a meta e atingimento por loja

O ranking de lojas usa barras com a meta marcada em 100%, em escala de 70% a 120%, e cores que separam quem bateu a meta (verde), quem ficou perto (cinza) e quem ficou abaixo de 95% (vermelho).




Figura 5. Receita e margem por categoria e mapa de calor de pedidos por dia e hora




Figura 6. Participação das formas de pagamento por trimestre e ticket médio com desconto concedido

Qualidade da última carga


Checagens executadas pelo ETL antes de publicar o mart. Uma falha aborta a carga.

pedido_id único após deduplicação	OK	Itens órfãos (sem pedido)	OK	SKU inexistente no cadastro	OK	preço não positivo	OK
desconto fora de [0, 0.5]	OK	duplicatas removidas em pedidos	1.710	pedidos cancelados excluídos	10.778	fato sem data válida	OK
margem inconsistente	OK	receita conciliada com staging	OK	devoluções mantidas com sinal negativo	2.155	linhas na fato_vendas	1.164.367

Figura 7. Resultado das checagens de qualidade da última carga, exibido no próprio painel

3.2 Dashboard do Data Mesh: painel integrado entre domínios

O público é a diretoria executiva, que precisa ver como a operação de um domínio afeta o resultado dos outros. A identidade visual associa uma cor a cada domínio, e todo gráfico mostra quais produtos de dados ele cruza. O filtro de período alterna entre os 18 meses, 2025 e o 1º semestre de 2026.






Figura 9. Série mensal com eventos operacionais e dispersão de ruptura contra NPS por loja

Campanhas: retorno e consentimento

ROAS = receita líquida dos pedidos atribuídos pela UTM dividida pelo investimento. A última coluna cruza pedidos de e-mail e push com o consentimento de marketing registrado no CRM.

marketing.investimento_diario marketing.campanhas vendas.pedidos clientes.perfil_cliente

Campanha	Rede	Vigência	Investimento	Receita atribuída	Pedidos	ROAS (traço vermelho = 1x)	Pedidos sem consentimento
Fidelidade 2026 push	Push App	jan/26 a jun/26	R\$ 25.627	R\$ 361.286	2.088	14,1x	792 (38%) sem opt-in
Fidelidade Ouro push	Push App	mar/25 a dez/25	R\$ 35.212	R\$ 445.102	2.635	12,6x	935 (35%) sem opt-in
Newsletter mensal	E-mail	jan/25 a jun/26	R\$ 31.362	R\$ 309.524	1.804	9,9x	662 (37%) sem opt-in
Reativação clientes inativos	E-mail	mar/26 a jun/26	R\$ 10.348	R\$ 86.746	489	8,4x	191 (39%) sem opt-in
Genéricos economia	Google Ads	fev/26 a abr/26	R\$ 81.084	R\$ 490.431	2.834	6x	não se aplica
Inverno 2026 imunidade	Google Ads	mai/26 a jun/26	R\$ 60.919	R\$ 291.680	1.654	4,8x	não se aplica
Antigripais inverno	Google Ads	mai/25 a ago/25	R\$ 115.749	R\$ 533.530	3.170	4,6x	não se aplica
Black Friday dermo	Meta Ads	nov/25	R\$ 55.104	R\$ 240.352	1.441	4,4x	não se aplica
Black Friday geral	Google Ads	nov/25	R\$ 50.227	R\$ 213.804	1.272	4,3x	não se aplica
Volta às aulas vitaminas	Google Ads	jan/25 a fev/25	R\$ 43.291	R\$ 171.451	1.033	4x	não se aplica
Dia das Mães 2026	Meta Ads	abr/26 a mai/26	R\$ 33.033	R\$ 128.133	775	4x	não se aplica
Dia das Mães perfumaria	Meta Ads	abr/25 a mai/25	R\$ 30.067	R\$ 114.966	681	3,8x	não se aplica
Natal presentes	Meta Ads	dez/25	R\$ 41.763	R\$ 142.618	844	3,4x	não se aplica
Dermo outono	Meta Ads	abr/25 a mai/25	R\$ 37.798	R\$ 127.515	767	3,4x	não se aplica
Outubro Rosa	Google Ads	out/25	R\$ 23.574	R\$ 71.467	428	3x	não se aplica
Carneval protetor solar	Meta Ads	fev/25 a mar/25	R\$ 25.399	R\$ 71.928	424	2,8x	não se aplica
Setembro Amarelo bem-estar	Meta Ads	set/25	R\$ 19.486	R\$ 39.467	229	2x	não se aplica
Black Friday TikTok	TikTok Ads	nov/25	R\$ 34.437	R\$ 53.439	317	1,6x	não se aplica
Verão proteção solar	TikTok Ads	jan/26 a fev/26	R\$ 82.780	R\$ 103.312	622	1,2x	não se aplica
Seca Brasília hidratação	TikTok Ads	jul/25 a set/25	R\$ 107.705	R\$ 112.065	642	1x	não se aplica

Figura 10. Retorno das campanhas e pedidos de e-mail e push sem consentimento de marketing

Catálogo de produtos de dados

Estado de cada porta de saída na última execução. Frescor medido contra o relógio do catálogo.

Produto	Dono	Versão	Acesso	Linhas	Checkagens	Frescor
clientes.perfil_cliente	squad-cx	3.1.0	restrito	28.000	12/12	cadastro
clientes.respostas_nps	squad-cx	1.0.0	interno	10.147	17/17	0h de 96h
logistica.entregas	squad-last-mile	1.1.0	interno	49.631	17/17	6h de 48h
logistica.ruptura_diaria_loja	squad-supply	2.0.0	público interno	9.767	19/19	30h de 30h
marketing.campanhas	squad-growth	1.0.0	público interno	20	13/13	cadastro
marketing.investimento_diario	squad-growth	1.3.0	público interno	1.802	14/14	30h de 48h
vendas.pedidos	squad-vendas	1.2.0	interno	178.495	23/23	30h de 36h
vendas.vendas_diarias_loja	squad-vendas	1.0.1	público interno	10.858	15/15	30h de 36h

Governança federada

Publicações bloqueadas e tentativas de leitura registradas pela plataforma.

Publicação bloqueada

clientes.respostas_nps_rascunho **rejeitado**

coluna fora do padrão snake_case: Loja
Pii em claro detectada (email) na coluna email
Nada foi gravado na porta de saída e os consumidores não enxergam o produto.

Leituras do catálogo

diretoria_bi → perfil_cliente	liberado
diretoria_bi → respostas_nps	liberado
diretoria_bi → respostas_nps_rascunho	indisponível
diretoria_bi → entregas	liberado
diretoria_bi → ruptura_diaria_loja	liberado
diretoria_bi → campanhas	liberado
diretoria_bi → investimento_diario	liberado
diretoria_bi → pedidos	liberado
diretoria_bi → vendas_diarias_loja	liberado
parceiro_externo_trade → perfil_cliente	não autorizado

Figura 11. Catálogo de produtos de dados e registros da governança federada

Parte 4. Análise dos dashboards

4.1 Análise do dashboard do Data Mart

A análise usa como referência os últimos 12 meses (julho de 2025 a junho de 2026) comparados aos 12 meses anteriores, que é o estado padrão do painel.

Crescimento forte, puxado pelo app

A receita líquida foi de **R\$ 34,5 milhões, alta de 22,2%**, com 249,6 mil pedidos (+15,4%) e ticket médio de R\$ 138 (+5,9%). Descontada a inflação de preços embutida na simulação, cerca de 4,5%, o crescimento real continua expressivo. O detalhamento por canal mostra de onde veio:

Tabela 7. Receita por canal

Canal	12 meses anteriores	Últimos 12 meses	Variação
Loja física	R\$ 21,0 mi	R\$ 24,3 mi	+15,8%
App	R\$ 3,6 mi	R\$ 6,8 mi	+86,6%
Site	R\$ 3,6 mi	R\$ 3,4 mi	-5,1%

O app quase dobrou e o site encolheu: há migração de clientes entre canais digitais, não só aquisição. Os canais digitais somam 29,5% da receita e têm ticket de R\$ 179 (app) e R\$ 185 (site), contra R\$ 126 na loja física. O mart não traz custo de entrega nem de aquisição por canal, então essa diferença de ticket ainda não diz nada sobre rentabilidade.

Meta quase batida no agregado, com três problemas localizados

A rede atingiu **97,2% da meta** (-0,4 p.p.). O ranking mostra que o agregado esconde uma distribuição desigual: 11 das 19 unidades estão em 100% ou mais, enquanto quatro lojas e o canal digital puxam o resultado para baixo.

- **Águas Claras Rua 12 (80%)**: loja inaugurada em março de 2025. A receita é coerente com uma rampa normal de maturação; o problema é a meta, 25% acima do esperado.
- **Planaltina (87%)**: a série da loja cai de forma contínua desde 2024. É um problema de demanda, não de meta.
- **Gama (94%) e Asa Sul (95%)**: a Asa Sul é a maior loja da rede, então 5 p.p. abaixo da meta pesam em valor absoluto.
- **Canal digital (95%)**: cresce muito, mas o cancelamento maior (4,5% contra 1,2% nas lojas) e os cupons do app reduzem a receita líquida frente ao planejado.

A categoria que mais vende é a que menos margem entrega

Medicamentos de referência lideram a receita (**R\$ 7,4 mi, 21% do total**) com **margem bruta de 14%**, o que representa só 10% da margem total. Dermocosméticos faturam quase o mesmo (R\$ 7,2 mi) com **margem de 39%** e respondem por cerca de 27% da margem. Genéricos também operam em 39%. A margem geral de 29,2% depende, portanto, do mix: cada ponto de participação que migra de referência para genérico ou dermocosmético melhora o resultado sem precisar vender mais.

Black Friday aumenta a receita e destrói margem

Filtrando 2025, a semana da Black Friday gerou **R\$ 118 mil por dia, 37% acima da média** do ano. Mas o desconto médio subiu de 5,7% para 20% da receita bruta e a **margem caiu de 29,5% para 18,1%**. Novembro de 2025 teve a menor margem mensal do período (27,4%), visível na linha de desconto do painel. Vale medir se os clientes captados na data voltam a comprar sem desconto; o mart tem `sk_cliente` para essa análise de coorte.

Sazonalidade e padrão de horário

Dezembro é o pico de receita (R\$ 3,7 mi em 2025). A categoria MIP e antigripais praticamente dobra entre maio e agosto (de R\$ 187 mil em janeiro para R\$ 411 mil em julho de 2025), o que pede reforço de compra antes do inverno seco. O mapa de calor mostra concentração no **sábado às 12h e às 18h** e nas sextas nos mesmos horários. Domingo tem 36% menos pedidos que sábado, o que sugere escala reduzida nesse dia.

Pagamento

Entre o 1º trimestre de 2024 e o 2º trimestre de 2026, o **Pix passou de 24% para 47%** da receita, enquanto débito caiu de 25% para 12% e convênio de 14% para 6%. A queda do convênio merece atenção comercial, porque normalmente representa clientes recorrentes vinculados a empresas.

Limites do Data Mart

O painel comercial mostra com clareza **o que** aconteceu, mas não **por que**. Ele diz que Planaltina está abaixo da meta, que o site perde receita e que o NPS não existe no modelo. Estoque, entregas, satisfação e mídia estão em outros sistemas, fora do escopo do mart. Responder essas perguntas exigiria novos marts ou uma integração central maior, que é exatamente o gargalo que o Data Mesh tenta evitar.

Recomendações

1. Revisar a metodologia de metas para lojas em maturação, usando curva de rampa em vez de crescimento linear.
2. Abrir uma investigação específica para Planaltina, com dados que o mart não possui (estoque, concorrência, satisfação).
3. Definir política de mix e de preço para aumentar genéricos e dermocosméticos frente a medicamentos de referência.
4. Limitar a profundidade de desconto na Black Friday por categoria e medir recompra dos clientes captados.
5. Investigar a queda do site: parte é migração para o app, mas a meta digital também não foi batida.

4.2 Análise do dashboard do Data Mesh

A análise usa os 18 meses completos. No período, a rede faturou **R\$ 25,3 milhões** em 178,5 mil pedidos, com 35% da receita vinda de canais digitais. O NPS geral foi **32**, com base em 10.147 respostas, e 87% das entregas chegaram no prazo.

A entrega é o principal motor do NPS digital

O cruzamento entre `clientes.respostas_nps` e `logistica.entregas` mostra uma relação quase linear entre atraso e satisfação:

Tabela 8. NPS por situação da entrega

Situação da entrega	Respostas	NPS
No prazo	3.275	44
Até 30 min de atraso	88	20
30 a 120 min	236	-27
Mais de 2 horas	162	-84
Extraviado	20	-100

Um atraso acima de 2 horas transforma praticamente todo cliente em detrator. A série mensal mostra quando isso se concentrou: durante a **migração do sistema de transporte**, as entregas no prazo caíram para **77,8% em outubro e 80,1% em novembro de 2025**, justamente no mês da Black Friday, com volume recorde de 4.924 envios. Por RA de destino, Planaltina, Sobradinho e Riacho Fundo ficam em 82% no prazo, contra 89% a 90% em Ceilândia, Guará e Sudoeste.

Ruptura de estoque derruba a satisfação na loja

O cruzamento entre `logistica.ruptura_diaria_loja` e as respostas de compras em loja mostra o mesmo padrão. Quando a loja tinha menos de 2% dos SKUs monitorados em falta no dia da compra, o NPS foi **43**. Com 10% ou mais, caiu para **-28**. Na visão por loja, a correlação entre ruptura média e NPS nas 18 lojas é de **-0,90**.

Tabela 9. Lojas com maior ruptura

Loja	Ruptura média	NPS	Atingimento da meta no mart
Planaltina	9,1%	-13	87%
Gama	7,7%	-9	94%
Sobradinho	5,6%	19	100%
Riacho Fundo	4,1%	22	102%
Média das demais lojas	cerca de 2,2%	entre 26 e 52	entre 95% e 103%

Aqui aparece o ganho mais claro do Data Mesh neste estudo. O Data Mart apontou Planaltina e Gama como lojas abaixo da meta sem conseguir explicar a causa. O cruzamento entre os produtos de logística e de clientes mostra que são as duas lojas com pior ruptura e os únicos NPS negativos da rede. A queda de vendas passa a ter hipótese concreta: falta de produto afasta o cliente.

Os eventos pontuais confirmam a leitura. Na **crise de antigripais**, a ruptura dessa categoria passou de cerca de 3% para **27% em junho e 37% em julho de 2025**, e o NPS de julho (26) foi o segundo menor de 2025. Na **greve do fornecedor** em março de 2026, a ruptura média subiu para 3,8%, concentrada em Sobradinho e Planaltina.

Marketing: um quarto da verba em mídia de retorno baixo

Foram investidos **R\$ 945 mil** em mídia, com **R\$ 4,1 milhões** em receita atribuída pela UTM, um ROAS geral de **4,3x**. O resultado por rede é muito desigual:

Tabela 10. Retorno por rede de mídia

Rede	Investimento	ROAS
Push App	R\$ 60,8 mil	13,3x
E-mail	R\$ 41,7 mil	9,5x
Google Ads	R\$ 374,8 mil	4,7x
Meta Ads	R\$ 242,7 mil	3,6x
TikTok Ads	R\$ 224,9 mil	1,2x

O TikTok recebeu **24% da verba** e devolveu pouco mais do que custou. A campanha "Seca Brasília hidratação" ficou em 1,0x, ou seja, pagou só a própria mídia, sem margem. Os canais próprios (push e e-mail) têm o melhor retorno com a menor verba.

Um risco de LGPD que nenhum domínio via sozinho

Ao cruzar os pedidos atribuídos a campanhas de e-mail e push com o consentimento registrado em `clientes.perfil_cliente`, o painel mostra que **2.580 dos 7.016 pedidos (36,8%) vieram de clientes sem opt-in de marketing**. Marketing não enxerga o consentimento, e o CRM não enxerga para quem as campanhas foram enviadas. O cruzamento só foi possível porque os dois domínios usam o mesmo pseudônimo de cliente, emitido pela plataforma, e porque o produto restrito pôde ser lido por um consumidor autorizado. O melhor retorno do marketing depende, em parte, de comunicação que a empresa não deveria estar enviando.

Governança funcionando

O painel de catálogo mostra os oito produtos publicados com todas as checagens aprovadas e dentro do SLA de frescor. A tentativa de publicar respostas NPS com e-mail em claro foi bloqueada antes de chegar a qualquer consumidor, e a leitura do perfil de clientes por um parceiro externo foi negada. As regras foram aplicadas por código, sem depender de revisão manual.

Limitações

- A atribuição por UTM é de último clique e superestima canais de fundo de funil, como push e e-mail.
- O NPS vem de uma amostra de cerca de 7,5% dos pedidos identificados. Faixas com poucas respostas, como extravio (20), devem ser lidas com cautela.
- A correlação entre ruptura e NPS foi construída na simulação. Em dados reais, seria necessário controlar fatores como perfil da RA e atendimento antes de afirmar causa.

Recomendações

1. Suspender imediatamente e-mail e push para clientes sem consentimento e incluir o consentimento como regra no contrato do produto de campanhas.

2. Priorizar reposição e estoque mínimo em Planaltina e Gama, e acompanhar se o NPS e o atingimento da meta reagem.
3. Criar alerta de SLA de entrega e plano de contingência para migrações de sistema, evitando coincidência com datas de pico.
4. Realocar parte da verba do TikTok para Google e canais próprios, mantendo teste controlado para medir incrementalidade real.
5. Antecipar a compra de antigripais para abril e maio, com base na ruptura observada em 2025.

Conclusão

As duas implementações partiram do mesmo cenário e chegaram a entregas diferentes. O **Data Mart** foi mais simples de construir e de validar. Em um único banco, com modelo estrela e um ETL com portões de qualidade, deu à área comercial números consistentes e rápidos sobre receita, margem, mix, metas e comportamento de compra. Para uma área com perguntas bem definidas, é uma solução difícil de superar em custo e clareza.

O **Data Mesh** exigiu mais estrutura: contratos, plataforma, catálogo, identificador global e regras de governança. Em troca, permitiu responder perguntas que atravessam áreas. As causas prováveis da queda de Planaltina, o efeito da migração do TMS sobre a satisfação e o risco de LGPD nas campanhas só apareceram quando produtos de domínios diferentes foram combinados com segurança.

A escolha depende do tamanho do problema organizacional, e não da moda tecnológica. Uma rede com poucos domínios e um time de dados pequeno começaria bem com data marts. À medida que as perguntas passam a cruzar áreas e o time central vira gargalo, os princípios do mesh ganham valor, e os data marts existentes podem ser publicados como produtos de dados de seus domínios.

Referências

- BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, 2018.
- DEHGHANI, Z. How to Move Beyond a Monolithic Data Lake to a Distributed Data Mesh. martinfowler.com, 2019.
- DEHGHANI, Z. Data Mesh Principles and Logical Architecture. martinfowler.com, 2020.
- DEHGHANI, Z. Data Mesh: Delivering Data-Driven Value at Scale. Sebastopol: O'Reilly Media, 2022.
- INMON, W. H. Building the Data Warehouse. 4. ed. Indianapolis: Wiley, 2005.
- KIMBALL, R.; ROSS, M. The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. 3. ed. Indianapolis: Wiley, 2013.
- REICHHELD, F. F. The One Number You Need to Grow. Harvard Business Review, v. 81, n. 12, p. 46-54, 2003.

Apêndice. Como reproduzir

Requisitos: Python 3.11 ou superior com `pandas`, `numpy`, `duckdb`, `pyarrow` e `pyyaml`. Os comandos abaixo rodam a partir da raiz do projeto.

Sequência de execução

```
pip install pandas numpy duckdb pyarrow pyyaml

python datamart/gerar_fontes.py          # 2.1 fontes do mart
python datamart/etl.py                  # 2.3 carga do mart
python dashboards/exportar_mart.py      # agregados do painel comercial

python datamesh/gerar_fontes.py         # 2.2 fontes dos domínios
export MESH_PSEUDO_KEY=$(python -c 'import secrets;print(secrets.token_hex(32))')
python datamesh/rodar_mesh.py           # 2.3 pipelines e publicação
python datamesh/consumo/analises.py     # cruzamentos entre domínios

python dashboards/build.py              # gera os dois dashboards HTML
```

Para Power BI, o banco `datamart_comercial.duckdb` pode ser lido pelo conector ODBC do DuckDB, e os Parquet das portas de saída do mesh podem ser importados diretamente. O modelo estrela já está pronto para relacionamentos um para muitos a partir das dimensões.